

Caio César de Oliveira
Diabetes em pessoas adultas entre 30 e 60 anos.

Estruturação de Variáveis para Modelagem Preditiva em Adultos Diabéticos: Uma Abordagem via Método CAPTO


Introdução

O presente documento detalha a estruturação e seleção de atributos para a construção de um modelo de *Machine Learning* supervisionado voltado para a análise de adultos diabéticos. Utilizando dados da Pesquisa Nacional de Saúde (PNS) de 2019, realizada pelo IBGE, o escopo da pesquisa foca em indivíduos entre 30 e 60 anos, com ênfase particular em fatores nutricionais.

A amostra base foi balanceada e filtrada para contrastar duas classes principais: um grupo de 555 indivíduos diabéticos (sem outras comorbidades relatadas) e um grupo de controle composto por 19.954 indivíduos saudáveis. Para a extração e organização metodológica de aproximadamente 80 variáveis relevantes, aplicou-se o Método CAPTO (Zárate et al.), dividindo o domínio do problema em seis dimensões fundamentais.

Metodologia de Seleção de Atributos (As 6 Dimensões)

O mapeamento estruturou as *features* do modelo preditivo nas seguintes categorias:



1. Hábitos Alimentares (Dimensão Principal)

Esta dimensão concentra a maior densidade de variáveis (40 no total) e é o núcleo da análise nutricional. Foi subdividida em três aspectos:

- Recordatório 24h: 22 variáveis binárias que mapeiam o consumo no dia anterior à pesquisa, abrangendo desde alimentos in natura até ultraprocessados.
- Frequência Semanal: 17 variáveis ordinais e numéricas que medem a regularidade do consumo de grupos alimentares específicos, incluindo a distinção entre produtos normais e diet/light, e o hábito de substituir refeições principais por lanches rápidos.
- Qualidade da Dieta: Uma variável categórica baseada na autopercepção do indivíduo sobre seu consumo de sal.

2. Ingestão de Bebidas

Focada na hidratação e no consumo de calorias líquidas e toxinas, composta por 11 variáveis:

- Bebidas Açucaradas e Leite: Frequência semanal e tipagem de refrigerantes, sucos industrializados e leite.
- Consumo de Álcool: Frequência de consumo, volume de doses por ocasião e indicadores de consumo abusivo (*binge drinking*).

3. Atividade Física e Sedentarismo

Engloba 13 variáveis que mapeiam o gasto calórico e os hábitos de repouso:

- Exercício Programado: Prática nos últimos três meses, frequência semanal, duração e tipo de esporte.
- Atividade Habitual e Deslocamento: Esforço físico exigido no ambiente de trabalho e uso de métodos de transporte ativos (caminhada ou bicicleta).
- Comportamento Sedentário: Horas diárias dedicadas ao consumo de mídia em telas (TV, computador, tablet ou celular).

4. Perfil Antropométrico

Compreende as medidas físicas diretas do indivíduo. Inclui o peso e a altura finais (priorizando dados aferidos aos informados).

- Nota Técnica: O Índice de Massa Corporal (IMC) não é uma variável nativa do *dataset* da PNS. Ele atua como uma variável derivada ($IMC = \text{peso} / \text{altura}^2$) que deve ser calculada durante a etapa de pré-processamento do *pipeline* de dados.

5. Perfil Sociodemográfico

Reúne 8 variáveis de contexto socioeconômico e demográfico, fundamentais para entender recortes de vulnerabilidade e acesso à saúde:

- Sexo, idade, cor/raça, estado civil, nível de escolaridade (padronizado), faixa de renda *per capita*, Unidade da Federação (UF) e situação censitária (urbana/rural).

6. Saúde e Comportamentos de Risco

Mapeia 14 variáveis relacionadas ao estado clínico geral e hábitos nocivos:

- Tabagismo: Carga tabágica atual, histórico de fumo e exposição passiva.
- Saúde Mental: Escala baseada no PHQ-2+ referente às duas últimas semanas, avaliando sono, energia, concentração, apetite e diagnóstico prévio de depressão.
- Autoavaliação: Percepção subjetiva do estado de saúde geral e do bem-estar físico e mental.

Tratamento de *Data Leakage* (Vazamento de Dados)

Para garantir que o modelo preditivo aprenda padrões de risco e não apenas decore consequências da doença, aplicou-se um filtro rigoroso de exclusão de variáveis que causariam *data leakage*. Foram retiradas 14 variáveis, classificadas em dois grupos de atenção:

1. Exclusão Obrigatória (Consequências Diretas)

Variáveis que só existem ou são alteradas *porque* o indivíduo já tem o diagnóstico não podem figurar nas *features* (variáveis preditoras). Isso inclui:

- A própria variável alvo (target): o diagnóstico de diabetes.
- Idade do primeiro diagnóstico ou casos restritos à gravidez.
- Tratamentos estabelecidos: uso de insulina, metformina, glibenclamida ou acompanhamento médico regular.
- Orientações médicas exclusivas para o manejo da doença (ex: medir glicemia em casa, examinar os pés, cortar massas e pães).
- Desfechos clínicos: exames de curva glicêmica/hemoglobina glicada, complicações (renais, visuais, amputações) e internações hospitalares decorrentes da doença.

2. Uso com Cautela (Comorbidades e Viés de Monitoramento)

Deve-se ter precaução com diagnósticos de hipertensão arterial e colesterol alto. Embora sejam fatores de risco comuns, podem atuar como variáveis de confusão. Além disso, a frequência temporal de exames de sangue e de aferição de pressão arterial foi desconsiderada, pois pacientes diabéticos são submetidos a um monitoramento clínico muito mais frequente, introduzindo um viés comportamental no algoritmo.

Conclusão

A aplicação do Método CAPTO permitiu estruturar um *dataset* de forma coerente com a fisiopatologia e os determinantes sociais do diabetes. A eliminação criteriosa de variáveis de consequência assegura a integridade do modelo de *Machine Learning*, garantindo que ele avalie fatores de risco reais (como dieta, sedentarismo e antropometria) em vez de atuar como um mero identificador de tratamentos médicos em andamento.